## Mini Project 01 - IMDB web scraping

```
library(tidyverse)
library(rvest) # scrape data from internet
Warning message in system("timedatectl", intern = TRUE):
"running command 'timedatectl' had status 1"
Warning message:
"Failed to locate timezone database"
- Attaching packages -
                                                         - tidyverse 1.3.1

√ ggplot2 3.3.5  
√ purrr 0.3.4

- Conflicts -
                                                     tidyverse_conflicts()
x dplyr::filter() masks stats::filter()
x purrr::flatten() masks jsonlite::flatten()
x dplyr::lag() masks stats::lag()
Attaching package: 'rvest'
 url <- "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating,desc"
print(url)
[1] "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating,desc"
# read html
```

```
imdb <- read_html(url)</pre>
```

```
# movie title

titles <- imdb %>%
   html_nodes("h3.lister-item-header") %>%
   html_text2()
```

## titles[1:10]

```
'1. The Shawshank Redemption (1994)' \cdot '2. The Godfather (1972)' \cdot '3. The Dark Knight (2008)' \cdot
```

```
# rating
ratings <- imdb %>%
  html_nodes("div.ratings-imdb-rating") %>%
  html_text2 %>%
  as.numeric()
```

```
ratings[1:10]
```

 $9.3 \cdot 9.2 \cdot 9 \cdot 9 \cdot 9 \cdot 9 \cdot 8.9 \cdot 8.8 \cdot 8.8$ 

<sup>&#</sup>x27;4. The Lord of the Rings: The Return of the King (2003)' · '5. Schindler\'s List (1993)' ·

<sup>&#</sup>x27;6. The Godfather Part II (1974)' · '7. 12 Angry Men (1957)' · '8. Pulp Fiction (1994)' · '9. Inception (2010)' ·

<sup>&#</sup>x27;10. The Lord of the Rings: The Two Towers (2002)'

```
# number of votes
num_votes <- imdb %>%
   html_nodes("p.sort-num_votes-visible") %>%
   html_text2()
```

```
# build a dataset

df <- data.frame(
    title = titles,
    rating = ratings,
    num_vote = num_votes
)

head(df)</pre>
```

	1			$\sim$
Δ	data.frame:	h	~	~
$\overline{}$	uata.name.	v	$\sim$	J

	title	rating	num_vote
	<chr></chr>	<dbl></dbl>	<chr></chr>
1	1. The Shawshank Redemption (1994)	9.3	Votes: 2,672,206   Gross: \$28.34M   Top 250: #1
2	2. The Godfather (1972)	9.2	Votes: 1,851,981   Gross: \$134.97M   Top 250: #2
3	3. The Dark Knight (2008)	9.0	Votes: 2,645,058   Gross: \$534.86M   Top 250: #3
4	4. The Lord of the Rings: The Return of the King (2003)	9.0	Votes: 1,841,599   Gross: \$377.85M   Top 250: #7
5	5. Schindler's List (1993)	9.0	Votes: 1,352,720   Gross: \$96.90M   Top 250: #6
6	6. The Godfather Part II (1974)	9.0	Votes: 1,268,068   Gross: \$57.30M   Top 250: #4

## Mini Project 02 - Specphone Phone Database

```
library(tidyverse)
library(rvest) # scrape data from internet

Warning message in system("timedatectl", intern = TRUE):
    "running command 'timedatectl' had status 1"
    Warning message:
    "Failed to locate timezone database"
```

```
url = read_html("https://specphone.com/Samsung-Galaxy-A04.html")
```

```
attr <- url %>%
   html_nodes("div.topic") %>%
   html_text2()

value <- url %>%
   html_nodes("div.detail") %>%
   html_text2()
```

```
data.frame(attributes=attr,value = value)
```

A data.frame: 31 × 2

	A data.frame: 31 × 2
attributes	value
<chr></chr>	<chr></chr>
วันเปิดตัว	ตุลาคม 2565
วันวางจำหน่าย	ยังไม่วางจำหน่าย
ขนาด	164.40 x 76.30 x 9.10 มม.
น้ำหนัก	192 กรัม
วัสดุ	Glass front, plastic back, plastic frame
SIM	รองรับ 2 ซิมการ์ด (nano sim, nano sim)
Technology	HSPA 42.2/5.76 Mbps, LTE-A
2G	850/900/1800/1900
3G	850/900/1900/2100
4G	850/900/1900/2100/2600
5G	-
ความเร็ว	HSPA 42.2/5.76 Mbps, LTE-A
ประเภท	PLS LCD
ขนาดหน้าจอ	6.50 นิ้ว
ความละเอียด	720 x 1600 pixels
ระบบปฏิบัติการ	Android 12
ชิปประมวลผล	Spreadtrum Unisoc SC9863A 1.6 GHz
ชิปกราฟิก	PowerVR GE8322
หน่วยความจำ	3 GB
ความจุ	32 GB
Memory Card	microSD (1)
กล้องหลัก	ตัวที่ 1: 50 MP, f/1.8, (wide), AF ตัวที่ 2: 2 MP, f/2.4, (depth)
ความละเอียดวีดีโอ	1080p@30fps
กล้องหน้า	ตัวที่ 1: 5 MP, f/2.2
Bluetooth	5.0, A2DP, LE
Wi-Fi	802.11 a/b/g/n/ac, dual-b
USB	Type-C
GPS	GLONASS, GALILEO, BDS
NFC	ไม่รองรับ
ความจุ	5,000 mAh
ประเภท	Non-removable Li-Po Batt

# All Samsung smart phone
samsung\_url <- read\_html("https://specphone.com/brand/Samsung")</pre>

```
# links to all samsung smartphone
links <- samsung_url %>%
  html_nodes("li.mobile-brand-item a") %>%
  html_attr("href")
```

```
full_links<-paste0("https://specphone.com",links)</pre>
```

```
for (link in full_links[1:10]) {
    ss_topic <- link %>%
    html_nodes("div.topic") %>%
    html_text2()
}
```

ERROR: Error in UseMethod("xml\_find\_all"): no applicable method for 'xml\_find\_a

ERROR: Error in UseMethod("xml\_find\_all"): no applicable method for 'xml\_find\_a

```
[1] "Progress .."
```

```
print(head(result),3)
```

```
attribute
                                                        value
      วันเปิดตัว
                                                มิถนายน 2565
2 วันวางจำหน่าย
                                              ยังไม่วางจำหน่าย
3
                                 165.40 x 76.90 x 8.40 มม.
          ขนาด
4
         น้ำหนัก
                                                      192 กรัม
           วัสดุ Glass front, plastic back, plastic frame
5
           SIM
                     รองรับ 2 ซึมการ์ด (nano sim, nano sim)
```

```
# write csv
write_csv(result, "result_ss_phone")
```